Статистический анализ данных. Спецкурс. Лекция 5. Проверка статистических гипотез

Ботанический сад-институт ДВО РАН

Кислов Д.Е. 19 ноября 2016 г.

• Ошибки первого и второго рода. Общая структура статистических критериев;

- Ошибки первого и второго рода. Общая структура статистических критериев;
- Критерии согласия;

- Ошибки первого и второго рода. Общая структура статистических критериев;
- Критерии согласия;
- Проверка данных на соответствие нормальному распределению. Критерий Шапиро-Уилка;

- Ошибки первого и второго рода. Общая структура статистических критериев;
- Критерии согласия;
- Проверка данных на соответствие нормальному распределению. Критерий Шапиро-Уилка;
- Непараметрические критерии. Критерий хи-квадрат. Критерий Колмогорова-Смирнова;

- Ошибки первого и второго рода. Общая структура статистических критериев;
- Критерии согласия;
- Проверка данных на соответствие нормальному распределению. Критерий Шапиро-Уилка;
- Непараметрические критерии. Критерий хи-квадрат. Критерий Колмогорова-Смирнова;
- Дисперсионный анализ;

- Ошибки первого и второго рода. Общая структура статистических критериев;
- Критерии согласия;
- Проверка данных на соответствие нормальному распределению. Критерий Шапиро-Уилка;
- Непараметрические критерии. Критерий хи-квадрат. Критерий Колмогорова-Смирнова;
- Дисперсионный анализ;
- Попарное сравнение в дисперсионном анализе (post-hoc анализ);

Понятия ошибок первого и второго рода

• Проверяемая гипотеза называется нулевой (H_0) ;

Понятия ошибок первого и второго рода

- Проверяемая гипотеза называется нулевой (H_0) ;
- Ошибкой первого рода является вероятность отвергнуть H_0 , когда она верна;

Понятия ошибок первого и второго рода

- Проверяемая гипотеза называется нулевой (H_0) ;
- Ошибкой первого рода является вероятность отвергнуть H_0 , когда она верна;
- Ошибкой второго рода является вероятность принять H_0 , когда верна альтернативная гипотеза;

Понятия ошибок первого и второго рода

- Проверяемая гипотеза называется нулевой (H_0) ;
- Ошибкой первого рода является вероятность отвергнуть H_0 , когда она верна;
- Ошибкой второго рода является вероятность принять H_0 , когда верна альтернативная гипотеза;

Обозначения

• Ошибка первого рода обозначается α ;

Понятия ошибок первого и второго рода

- Проверяемая гипотеза называется нулевой (H_0) ;
- Ошибкой первого рода является вероятность отвергнуть H_0 , когда она верна;
- Ошибкой второго рода является вероятность принять H_0 , когда верна альтернативная гипотеза;

Обозначения

- Ошибка первого рода обозначается lpha;
- ullet Ошбика второго рода обозначается eta;

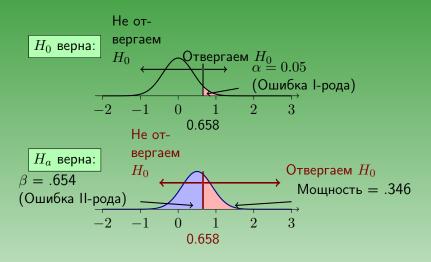
Понятия ошибок первого и второго рода

- Проверяемая гипотеза называется нулевой (H_0) ;
- Ошибкой первого рода является вероятность отвергнуть H_0 , когда она верна;
- Ошибкой второго рода является вероятность принять H_0 , когда верна альтернативная гипотеза;

Обозначения

- Ошибка первого рода обозначается α ;
- Ошбика второго рода обозначается β ;
- $1-\beta$ мощность критерия (вероятность принять альтернативную гипотезу, когда она верна);

Ошибки I-го и II-го рода. Мощность критериев.



Назначение

Проверка соответствия наблюдаемых данных теоретическим законам распределения

<u>Назначение</u>

Проверка соответствия наблюдаемых данных теоретическим законам распределения

Наиболее распространенные критерии согласия

ullet Критерий χ^2 ;

Назначение

Проверка соответствия наблюдаемых данных теоретическим законам распределения

Наиболее распространенные критерии согласия

- ullet Критерий χ^2 ;
- Критерий Колмогорова;

Назначение

Проверка соответствия наблюдаемых данных теоретическим законам распределения

Наиболее распространенные критерии согласия

- ullet Критерий χ^2 ;
- Критерий Колмогорова;
- Критерий Шапиро-Уилка;

Назначение

Проверка соответствия наблюдаемых данных теоретическим законам распределения

Наиболее распространенные критерии согласия

- ullet Критерий χ^2 ;
- Критерий Колмогорова;
- Критерий Шапиро-Уилка;
- другие специфичные критерии

Критерий χ^2 (К. Пирсон, 1900)

Формулировка критерия

Пусть $x_1, x_2, ..., x_N$ – выборочные данные. Проверяется гипотеза о том, что выборка получена из закона распределения F(x). Тогда интервал возможных значений разбивается на kчастей, в каждой из которых определяется число выборочных элементов. Далее, вычисляется статистика критерия:

$$\hat{\chi}^2 = N \sum_{i=1}^k \frac{(n_i/N - P_i)^2}{P_i},$$

$$P_i = F(b_{i+1}) - F(b_i)$$

 b_i – границы разбиения. Величина $\hat{\chi}^2$ имеет распределение χ^2 с k-1 степенями свободы.

Если вычисленное $\hat{\chi}^2$ оказывается больше χ^2 квантиля для уровня α , то гипотеза о соответствии данному закону распределения отвергается при уровне значимости α .

Формулировка критерия

Пусть проверяется соответствие выборочных данных x_1,x_2,\dots,x_N закону распределения F(x). Исходя из выборочных данных формируется выборочная функция распределения $F_n(x)$

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{X_i \le x}$$

$$\forall t > 0: \lim_{n \to \infty} P(\sqrt{n}D_n \le t) \approx K(t) = \sum_{j=-\infty}^{+\infty} (-1)^j e^{-2j^2 t^2}$$

$$D_n = \sup_x |F_n(x) - F(x)|$$

Формулировка критерия

Пусть проверяется соответствие выборочных данных x_1,x_2,\dots,x_N закону распределения F(x). Исходя из выборочных данных формируется выборочная функция распределения $F_n(x)$

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{X_i \le x}$$

$$\forall t > 0: \lim_{n \to \infty} P(\sqrt{n}D_n \le t) \approx K(t) = \sum_{j=-\infty}^{+\infty} (-1)^j e^{-2j^2 t^2}$$

$$D_n = \sup_x |F_n(x) - F(x)|$$

Как быть если параметр распределения нужно оценивать по выборке?



Формулировка критерия

Пусть проверяется соответствие выборочных данных x_1, x_2, \dots, x_N закону распределения F(x). Исходя из выборочных данных формируется выборочная функция распределения $F_n(x)$

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{X_i \le x}$$

$$\forall t > 0: \lim_{n \to \infty} P(\sqrt{n}D_n \le t) \approx K(t) = \sum_{j=-\infty}^{+\infty} (-1)^j e^{-2j^2 t^2}$$

$$D_n = \sup_x |F_n(x) - F(x)|$$

Как быть если параметр распределения нужно оценивать по выборке?

Для случая нормального распределения используется поправка Лильефорса...



Формулировка критерия

Пусть проверяется соответствие выборочных данных x_1,x_2,\dots,x_N закону распределения F(x). Исходя из выборочных данных формируется выборочная функция распределения $F_n(x)$

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{X_i \le x}$$

$$\forall t > 0: \lim_{n \to \infty} P(\sqrt{n}D_n \le t) \approx K(t) = \sum_{j=-\infty}^{+\infty} (-1)^j e^{-2j^2 t^2}$$

$$D_n = \sup_x |F_n(x) - F(x)|$$

Для проверки однородности двух выборок применяют критерий Смирнова (построенный на базе распределения Колмогорова).



Критерий Шапиро-Уилка

Формулировка критерия

Статистика критерия имеет вид:

$$W = \frac{1}{s^2} \left[\sum_{i=1}^{n} a_{n-i+1} (x_{n-i+1} - x_i) \right]^2$$

$$s^{2} = \sum_{i=1}^{n} (x_{i} - \overline{x})^{2}, \overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_{i}.$$

Коэффициенты a_i находятся по таблицам; Критерий фактически основывается на отношениях оценок дисперсий распределения. Данный критерий является одним из самых мощных в плане проверки нормальности распределений.